

UNIVERSIDAD DEL ISTMO
FACULTAD DE INGENIERÍA

TAREA #3

INTRODUCCIÓN A SERIES DE TIEMPO

KATHERINE MARIELA DIÉGUEZ URBINA

Guatemala, 25 de octubre de 2026

1. Parte 0: Procesos simulados

1.1. 0.1 Derivaciones a mano

Consideramos el modelo AR(1)

$$Y_t = c + \phi\, Y_{t-1} + \varepsilon_t, \qquad \varepsilon_t \overset{iid}{\sim} N(0, \sigma^2),$$

y suponemos que es estacionario, con $|\phi| < 1$. Usaremos dos hechos: por estacionariedad, la media y la varianza de Y_t no dependen de t; y ε_t es independiente de $Y_{t-1}, Y_{t-2}, \ldots$, por lo que $\mathrm{Cov}(\varepsilon_t, Y_{t-k}) = 0$ para todo $k \geq 1$.

Media. Tomando esperanza en ambos lados del modelo y usando $E[\varepsilon_t] = 0$:

$$E[Y_t] = c + \phi\, E[Y_{t-1}].$$

Por estacionariedad, $E[Y_t] = E[Y_{t-1}] = \mu$, de modo que

$$\mu = c + \phi\mu \quad \Longrightarrow \quad \mu(1-\phi) = c \quad \Longrightarrow \quad \boxed{E[Y_t] = \frac{c}{1-\phi}}.$$

Varianza. La constante c no aporta varianza y, como ε_t es independiente de Y_{t-1}, las varianzas se suman:

$$\mathrm{Var}(Y_t) = \phi^2\, \mathrm{Var}(Y_{t-1}) + \sigma^2.$$

Por estacionariedad, $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1}) = \gamma_0$, así que

$$\gamma_0 = \phi^2\gamma_0 + \sigma^2 \quad \Longrightarrow \quad \boxed{\mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}}.$$

Mientras más cerca está ϕ de 1, mayor es la varianza: los choques se acumulan porque tardan más en olvidarse.

Autocorrelación. Para $k \geq 1$, sustituimos Y_t por el modelo:

$$\gamma_k = \mathrm{Cov}(Y_t, Y_{t-k}) = \mathrm{Cov}(c + \phi Y_{t-1} + \varepsilon_t,\ Y_{t-k}) = \phi\ \mathrm{Cov}(Y_{t-1}, Y_{t-k}) + \mathrm{Cov}(\varepsilon_t, Y_{t-k}).$$

La covarianza de una constante es cero, y el último término también es cero porque ε_t es independiente del pasado. Además, Y_{t-1} y Y_{t-k} están separados $k-1$ pasos, así que su covarianza es γ_{k-1}. Obtenemos la recursión

$$\gamma_k = \phi\, \gamma_{k-1},$$

que, aplicada repetidamente desde γ_0, da $\gamma_k = \phi^k\gamma_0$. Dividiendo entre γ_0:

$$\boxed{\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k}.$$

Es decir, la memoria del proceso decae exponencialmente: con $\phi = 0.5$, la correlación con el día anterior es 0.5, con dos días atrás es 0.25, y así sucesivamente.

Caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, el modelo es $Y_t = Y_{t-1} + \varepsilon_t$. Desenrollando la recursión,

$$Y_t = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t = \sum_{i=1}^{t} \varepsilon_i.$$

Como las ε_i son independientes, sus varianzas se suman:

$$\boxed{\mathrm{Var}(Y_t) = \sum_{i=1}^{t} \sigma^2 = t\,\sigma^2}.$$

La caminata aleatoria no es estacionaria porque su varianza crece con t, mientras que la estacionariedad débil exige una varianza constante en el tiempo. El proceso se aleja cada vez más de su punto de partida y no existe un nivel fijo alrededor del cual fluctúe. Esto es consistente con la fórmula de la varianza del AR(1): con $\phi = 1$, la expresión $\sigma^2/(1-\phi^2)$ no está definida, porque no hay una varianza estable a la cual llegar.

1.2. 0.2 Simulación

Simulamos $n = 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$, descartando los primeros 200 pasos para que el valor inicial $Y_0 = 0$ no influya. La Figura 1 muestra una realización para cada $\phi \in \{0, 0.5, 0.9, 1\}$.

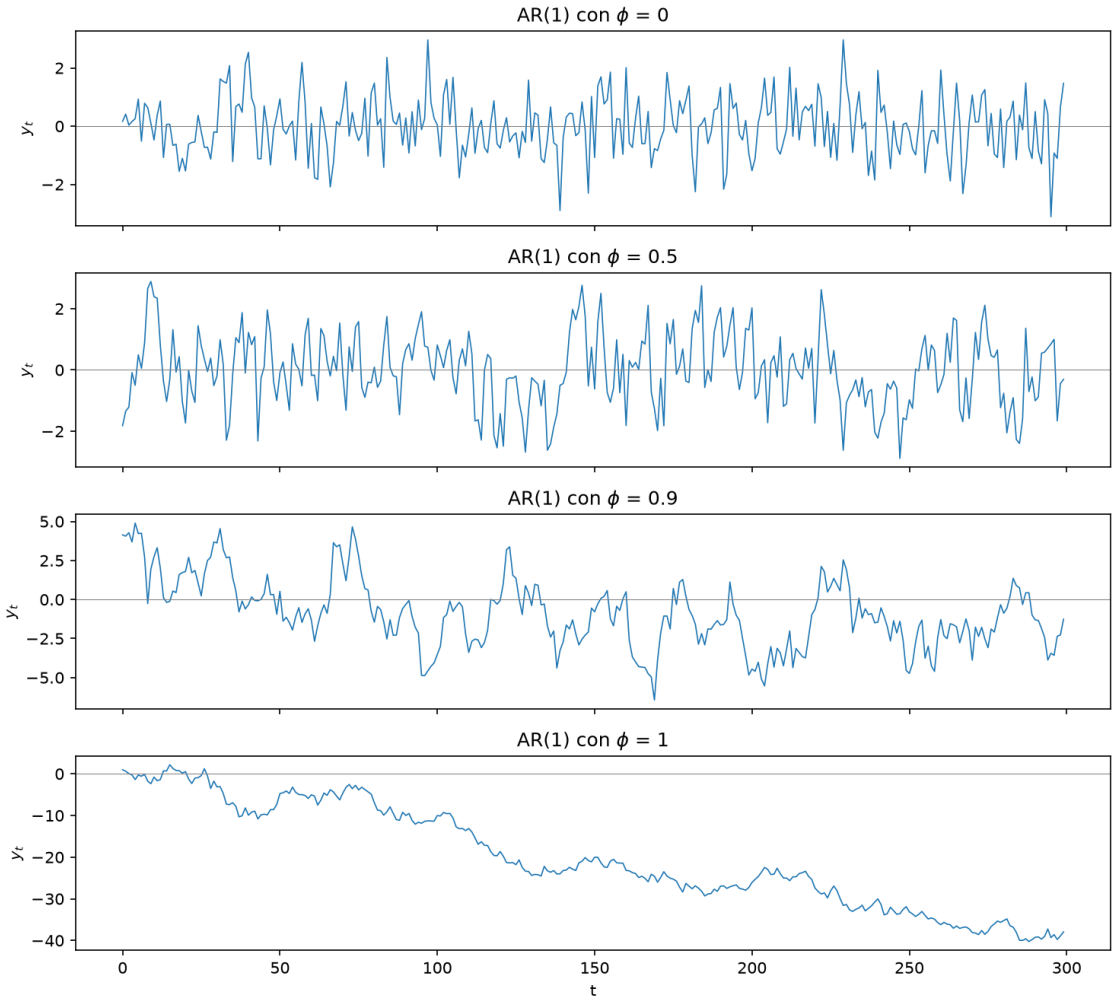


Figura 1: Una realización de un AR(1) para cada valor de ϕ (semilla 2026).

Con $\phi = 0$ la serie es ruido blanco, sin patrón alguno. Al aumentar ϕ aparecen rachas cada vez más largas por encima o por debajo de cero y la amplitud crece, consistente con $\mathrm{Var}(Y_t) = \sigma^2/(1-\phi^2)$. Aun así, con $\phi = 0.9$ la serie siempre regresa hacia su media. La caminata aleatoria ($\phi = 1$), en cambio, se aleja de su punto de partida sin regresar, reflejo de que su varianza crece con t.

Para $\phi = 1$ el calentamiento no elimina el efecto del valor inicial, porque la caminata aleatoria nunca olvida: las 300 observaciones conservadas son Y_{200} más una suma de choques nuevos. Sin embargo, esto no afecta a r_k, porque el valor inicial solo desplaza toda la serie por una constante, y r_k trabaja con las desviaciones $y_t - \bar{y}$, en las que esa constante se cancela.

Cuadro 1: Resultados de 5 000 réplicas de un AR(1) con $n = 300$. Entre paréntesis, el error estándar de cada promedio. Semillas: 20260, 20261, 20262 y 20263 para $\phi = 0, 0.5, 0.9, 1$.

ϕ	$\overline{r_1}$	$\overline{r_5}$	ϕ^5	Tasa de rechazo	$\overline{\hat{\phi}}_{\mathrm{OLS}}$
0	−0.0029 (0.0008)	−0.0025 (0.0008)	0	0.0476 (0.0030)	−0.0029 (0.0008)
0.5	0.4899 (0.0007)	0.0207 (0.0010)	0.0313	1.0000 (0.0000)	0.4915 (0.0007)
0.9	0.8842 (0.0004)	0.5357 (0.0014)	0.5905	1.0000 (0.0000)	0.8876 (0.0004)
1	0.9755 (0.0002)	0.8819 (0.0009)	1	1.0000 (0.0000)	0.9819 (0.0002)

La Tabla 1 resume las simulaciones. La tasa de rechazo es la fracción de réplicas en que $|r_1| > 1.96/\sqrt{n}$.

1.3. 0.3 Interpretación

Tasa de rechazo con $\phi = 0$. La tasa de rechazo es 0.0476, con error estándar 0.003, consistente con el 5 % esperado. Bajo ruido blanco, $r_1 \approx N(0, 1/n)$, de modo que las bandas $\pm 1.96/\sqrt{n}$ contienen a r_1 el 95 % de las veces: el 5 % restante son falsos positivos por construcción, es decir, el error tipo I de la prueba. Para $\phi \geq 0.5$ la prueba rechaza en el 100 % de las réplicas. El promedio de r_1 con $\phi = 0$ es ligeramente negativo (-0.0029), cercano al sesgo conocido de $-1/n \approx -0.0033$ que introduce restar la media muestral.

La caminata aleatoria. Con $\phi = 1$, el promedio de r_5 es 0.88, lejos del valor $\phi^5 = 1$. La fórmula $\rho_k = \phi^k$ supone estacionariedad, que la caminata aleatoria no cumple, así que no existe una autocorrelación poblacional que r_k estime; además, $\bar{y}$ depende de por dónde deambuló cada realización. Lo que sí se observa es que la ACF decae muy lentamente ($r_1 = 0.98$, $r_5 = 0.88$), la señal característica de una serie no estacionaria.

Sesgo del estimador OLS. El estimador OLS de ϕ subestima sistemáticamente el valor verdadero: las diferencias son de -0.0085, -0.0124 y -0.0181 para $\phi = 0.5$, 0.9 y 1, entre 12 y 86 veces su error estándar. El sesgo crece con ϕ y coincide con la aproximación conocida de $-(1 + 3\phi)/n$ para un AR(1) con intercepto (por ejemplo, -0.0123 para $\phi = 0.9$). Como el sesgo es de orden $1/n$, el estimador es consistente, pero con $n = 300$ el sesgo todavía es visible, y es mayor cuando el proceso se acerca a una raíz unitaria.

1.4. 0.4 Las dos razones para reprobar

Simulamos procesos sin memoria, $Y_t = m_t + \varepsilon_t$ con $\varepsilon_t \overset{iid}{\sim} N(0, 1)$, para dos medias que cambian con el tiempo: (a) una tendencia lineal $m_t = 2t/300$ y (b) un patrón semanal con $m_t = -1.5$ si t mód $7 = 6$ y $m_t = 0.25$ en los demás días. Incluimos ruido blanco ($m_t = 0$) como referencia. La Figura 2 muestra una realización de cada proceso y la Tabla 2 resume 5 000 réplicas de cada uno.

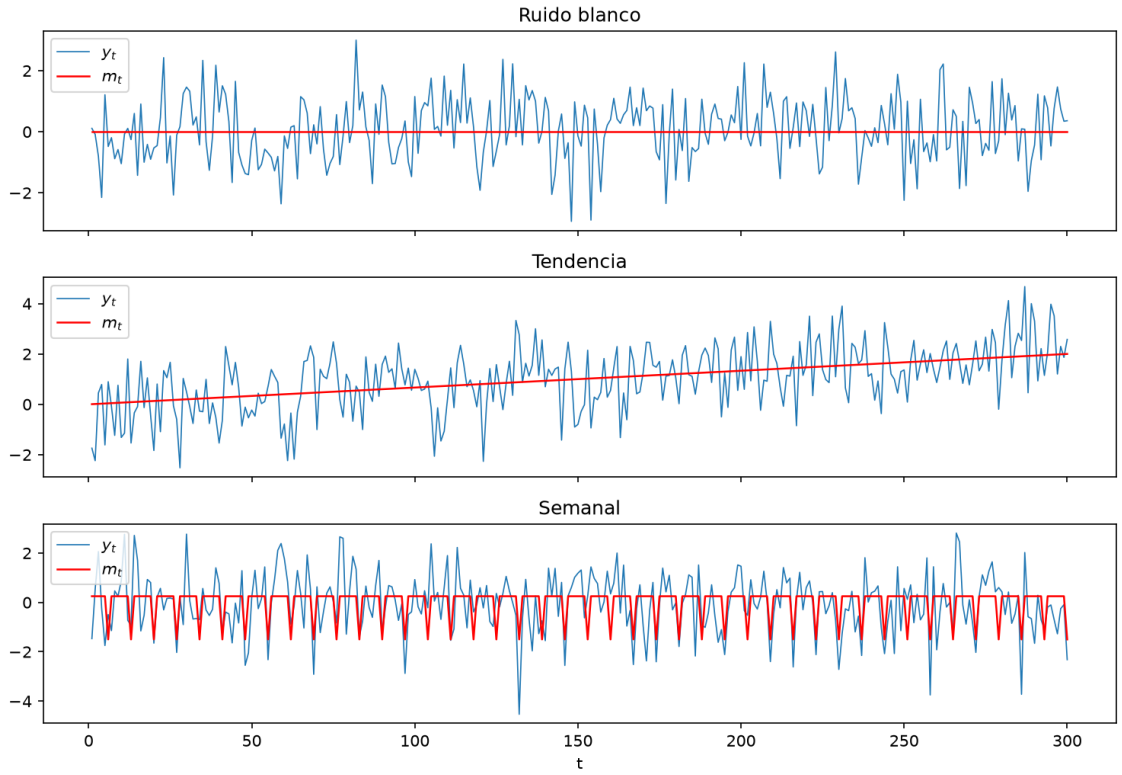


Figura 2: Una realización de cada proceso (azul) y su media m_t (rojo), semilla 2027.

Cuadro 2: Resultados de 5 000 réplicas de procesos sin memoria con $n = 300$. Entre paréntesis, el error estándar. Semillas: 20264, 20265 y 20266.

Proceso	$\overline{r_1}$	$\overline{r_7}$	Tasa de rechazo (r_1)	$\overline{\hat{\phi}}_{\text{OLS}}$
Ruido blanco	−0.0030 (0.0008)	−0.0050 (0.0008)	0.0410 (0.0028)	−0.0030 (0.0008)
Tendencia	0.2452 (0.0008)	0.2305 (0.0008)	0.9856 (0.0017)	0.2465 (0.0008)
Semanal	−0.0463 (0.0007)	0.2638 (0.0008)	0.0990 (0.0042)	−0.0467 (0.0007)

La tendencia reprueba sin tener memoria. La prueba de retardo 1 rechaza en el 98.6 % de las réplicas del proceso con tendencia, y el OLS estima $\hat{\phi} \approx 0.25$, aunque los errores son independientes. Con una tendencia, $\bar{y}$ no representa la media de ningún día: los primeros días quedan casi todos por debajo y los últimos por encima, de modo que cada día y su vecino se desvían en la misma dirección. La magnitud es predecible: la varianza de m_t es aproximadamente $2^2/12 \approx 0.33$, que es la cuarta parte de la varianza total, 1.33. Además, $r_7 \approx r_1$: la ACF casi no decae, la señal de una media no constante.

El patrón semanal pasa con estructura. El proceso semanal rechaza solo en el 9.9 % de las réplicas, aunque tiene una estructura fuerte: su r_7 promedio es 0.26. La prueba de retardo 1 solo compara cada día con el anterior, y a ese rezago el patrón casi se cancela; la covarianza teórica de m_t es -0.0625 a rezago 1 y 0.375 a rezago 7, que divididas entre la varianza total (1.375) dan -0.045 y 0.27, en línea con lo simulado.

Conexión con RANDU. RANDU pasaba las pruebas de independencia sencillas, pero sus tríos consecutivos caen en solo 15 planos. En ambos casos existe una estructura que la prueba de retardo 1 no puede detectar porque no mira en esa dirección. Pasar una prueba no demuestra independencia: solo indica que no está presente el tipo de dependencia que esa prueba busca.

Por último, la tasa de rechazo del ruido blanco (0.041) quedó algo por debajo del 5 % nominal; la aproximación $r_1 \approx N(0, 1/n)$ no es exacta para $n = 300$, ya que r_1 tiene un pequeño sesgo negativo y una varianza algo menor que $1/n$.

1.5. 0.5 La prueba que sí ve

Implementamos la prueba de Ljung–Box y la verificamos contra `acorr_ljungbox` de `statsmodels`, con resultados idénticos. La aplicamos con $m = 10$, como pide el enunciado, y con $m = 6 \approx \log(300)$, la regla que favorece Tsay. Usamos las mismas semillas que en 0.4, de modo que las 5 000 series de cada proceso son idénticas a las de esa sección y la comparación entre pruebas es directa.

Cuadro 3: Tasa de rechazo al 5 % en 5 000 réplicas. Entre paréntesis, el error estándar.

Proceso	Retardo 1	Ljung–Box $m = 6$	Ljung–Box $m = 10$
Ruido blanco	0.0410 (0.0028)	0.0470 (0.0030)	0.0556 (0.0032)
Tendencia	0.9856 (0.0017)	1.0000 (0.0000)	1.0000 (0.0000)
Semanal	0.0990 (0.0042)	0.1946 (0.0056)	0.9514 (0.0030)

Para el ruido blanco, las tres pruebas rechazan cerca del 5 %: aunque Ljung–Box examina varios rezagos, es una sola prueba y mantiene su nivel. Si en cambio se revisaran 10 rezagos por separado, la probabilidad de que alguno saliera de las bandas por azar sería cercana a $1 - 0.95^{10} \approx 40\,\%$. El proceso con tendencia es rechazado por todas las pruebas, porque todos sus r_k son grandes; Ljung–Box, igual que la prueba de retardo 1, detecta que la serie no es ruido blanco, pero no distingue memoria de media no constante.

La diferencia está en el proceso semanal. La prueba de retardo 1 lo rechaza en el 9.9 % de las réplicas, y Ljung–Box con $m = 10$ en el 95.1 %: al sumar r_k^2 para $k = 1, \ldots, 10$, el estadístico incluye $r_7 \approx 0.26$, donde vive la estructura. Con $m = 6$, en cambio, la tasa es apenas 19.5 %, porque la ventana no alcanza el rezago 7; el pequeño aumento respecto a la prueba de retardo 1 viene de acumular las correlaciones negativas pequeñas de los rezagos 1 a 6. En este caso, la regla $m \approx \log(n)$ falla porque el periodo estacional es mayor que m, mientras que la recomendación de FPP2 de usar $m = 2s$ con estacionalidad sí capturaría el patrón: la ventana de la prueba debe cubrir al menos un periodo estacional completo.

2. Parte 1: Limpieza

2.1. 1.1 Los datos

Leímos `InvoiceNo`, `StockCode` y `CustomerID` como texto. Son identificadores, no cantidades, y si se dejan a pandas su tipo se adivina mal: `InvoiceNo` mezcla números con códigos de cancelación como `C536379`; `StockCode` mezcla códigos numéricos con otros como `85123A` o `POST`, de modo que un mismo producto podría aparecer como número en una fila y como texto en otra; y `CustomerID`, al tener valores vacíos, se convertiría a decimal (`17850.0`).

Los datos tienen 541 909 filas, 25 900 facturas, 4 070 códigos de producto distintos y 4 372 clientes, entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011. El 24.9 % de las filas no tiene `CustomerID`.

El número de códigos de producto sobrestima el número de productos, porque incluye códigos que no son productos, como `POST`.

2.2. 1.2 Casos a investigar

(a) Duplicados exactos: se eliminan. Hay 5 268 filas idénticas a otra en todas las columnas, incluida la hora, por un total de £21 741 (alrededor del 0.2 % de la venta). Un sistema de facturación normalmente acumularía las unidades de un mismo producto en una sola línea, por lo que interpretamos estas filas como registros dobles.

(b) Facturas que no empiezan con un dígito. Hay dos prefijos. Las facturas con prefijo `C` (9 288 filas en 3 836 facturas) son cancelaciones y **se conservan**: todas tienen cantidad negativa, de modo que al sumarlas restan el día en que ocurren, como pide la definición de venta neta. Representan unos £896 800, cerca del 8 % de la venta bruta. Las tres facturas con prefijo `A` (`A563185` a `A563187`) son ajustes contables por deuda incobrable (*Adjust bad debt*), sin cliente, y **se eliminan**: no reflejan ninguna venta y restarían £11 062 al 12 de agosto de 2011.

(c) Códigos que no son productos. Primero convertimos todos los `StockCode` a mayúsculas: 112 productos aparecían con dos códigos que solo diferían en mayúsculas y minúsculas (por ejemplo, `85123A` y `85123a`). Después revisamos los códigos que no empiezan con cinco dígitos (Tabla 4). Eliminamos los cargos de envío, porque son un servicio y no mercancía; los costos, comisiones y ajustes contables, porque no son ventas; los ajustes manuales (`M`), porque mezclan correcciones de todo tipo; y los vales de regalo, porque su canje posterior ya aparece como venta y contarlos duplicaría ese dinero. Conservamos los descuentos (`D`), porque reducen lo que el cliente pagó por sus productos y forman parte de la venta neta. Los códigos `DCGS` con descripción real (bolsas de fiesta, collares para perro, etc.) son productos vendidos por la tienda en línea y se conservan.

Cuadro 4: Códigos de `StockCode` que no empiezan con cinco dígitos. Importe en libras antes de limpiar.

Código	Descripción	Filas	Importe (£)	Decisión
`POST`, `DOT`, `C2`	Envío y transporte	2 110	279 462	Se elimina
`AMAZONFEE`	Comisión de Amazon	34	−221 521	Se elimina
`M`, `m`	Ajuste manual	572	−68 672	Se elimina
`B`	Deuda incobrable	3	−11 062	Se elimina
`CRUK`	Comisión benéfica	16	−7 933	Se elimina
`BANK CHARGES`	Comisión bancaria	37	−7 176	Se elimina
`S`	Muestras	63	−3 049	Se elimina
`gift_0001_*`	Vales de regalo	34	686	Se elimina
`PADS`	Registro de relleno	4	0	Se elimina
`D`	Descuento	77	−5 696	Se conserva
`DCGS*`	Productos de la tienda en línea	47	398	Se conservan

(d) Precios iguales a cero o negativos: se eliminan. Las dos filas con precio negativo son los ajustes por deuda incobrable de (b). Las 2 515 filas con precio cero tienen descripciones como *check*, *damaged*, *found* o *thrown away*, o ninguna descripción: son ajustes de inventario, no ventas. Su importe es cero, así que no afectan la serie diaria, pero las eliminamos porque 40 de ellas tienen cliente y, en la Parte 6, una factura con productos sin costo contaría como una compra.

(e) Cantidades negativas en facturas que no son cancelaciones: se eliminan. Las 1 336 filas tienen precio cero, ninguna tiene cliente y su importe total es cero. Sus descripciones (*damaged*, *check*, *thrown away*, *Unsaleable, destroyed*) indican que son salidas de inventario, no devoluciones ni ventas. Todas quedan eliminadas por la regla de (d), por lo que esta regla, aplicada después, no elimina ninguna fila adicional.

(f) Filas sin `CustomerID`: se conservan para la serie. Son el 24.9 % de las filas, pero el 14.9 % de la venta neta (£1.45 millones). Ninguna factura mezcla filas con y sin cliente: el identificador falta en facturas completas, lo que sugiere compras de clientes no registrados. Para la serie de ventas solo importa cuánto se vendió, así que eliminarlas subestimaría la venta. En la Parte 6, en cambio, necesitamos saber quién compró, y ahí se excluyen.

2.3. 1.3 Bitácora de limpieza

La Tabla 5 resume la limpieza. Las reglas se aplican en el orden indicado, cada una sobre lo que dejó la anterior, después de convertir todos los `StockCode` a mayúsculas.

Cuadro 5: Bitácora de limpieza. Antes de limpiar: 541 909 filas y £9 747 748. Después: 531 275 filas y £9 726 614.

Orden	Regla	Filas eliminadas	Importe eliminado (£)
1	(a) Duplicados exactos	5 268	21 741
2	(b) Facturas que no son venta ni cancelación	3	−11 062
3	(c1) Pares venta / cancelación manual del mismo monto	14	0
4	(c2) Resto de códigos que no son productos	2 857	10 455
5	(d) Precio cero o negativo	2 492	0
6	(e) Cantidad negativa fuera de cancelaciones	0	0

El orden afecta los conteos. La regla (c1), explicada en 1.4, elimina siete pares formados por una cancelación manual y la venta que anula; como cada par suma cero, su importe neto es nulo. Debe aplicarse antes de (c2), que elimina los demás códigos que no son productos, incluidas las cancelaciones manuales restantes: en el orden inverso, (c2) eliminaría la cancelación y dejaría la venta errónea. La regla (d) elimina 2 492 filas y no las 2 515 con precio no positivo de los datos originales, porque dos de ellas (los ajustes por deuda incobrable) ya las eliminó (b) y otras 21 eran duplicados eliminados por (a). La regla (e) no elimina ninguna fila porque todas las cantidades negativas fuera de cancelaciones tenían precio cero.

El importe neto de (c2) es pequeño, pero esconde montos grandes de signo opuesto: los cargos de envío sumaban alrededor de £279 000 y las comisiones y ajustes alrededor de −£269 000. En conjunto, la limpieza reduce la venta neta total en unos £21 100.

2.4. 1.4 Las seis líneas más grandes

Las seis líneas con mayor |Quantity × UnitPrice| en los datos crudos corresponden a tres episodios.

Papel de manualidades. El 9 de diciembre de 2011 a las 9:15, el cliente 16446 pidió 80 995 unidades de *Paper Craft, Little Birdie* (£168 469.60), y la factura se canceló doce minutos después. Es casi seguro un error de digitación. Ninguna regla de limpieza elimina estas líneas, porque son una venta y una cancelación con apariencia normal, pero al netear por día se anulan.

Frascos de cerámica. El 18 de enero de 2011, el cliente 12346 pidió 74 215 frascos (£77 183.60) a las 10:01 y los canceló a las 10:17. Igual que en el caso anterior, la limpieza no las elimina y el neteo diario las anula. Esto solo funciona porque la cancelación ocurrió el mismo día: si se hubiera registrado al día siguiente, la serie tendría dos picos falsos de signo opuesto.

Canastas de picnic. El 10 de junio de 2011, en 17 minutos, el cliente 15098 compró 60 canastas sueltas (£297); luego se registraron 60 unidades de un producto que ya es un paquete de 60 piezas (£38 970); esa línea se anuló con una cancelación manual (código `M`) por el mismo monto; se registró un solo paquete (£649.50) y se canceló la compra suelta. La venta real fue de £649.50, que es lo que da el neto del día en los datos crudos. Nuestra primera versión de la limpieza eliminaba la cancelación manual (por ser código `M`) pero conservaba la venta errónea, lo que inflaba ese día en £38 970. Para corregirlo agregamos la regla (c1), que elimina juntas una cancelación manual y una venta del mismo cliente, el mismo día y por el mismo monto. Como cada par suma cero, esta regla nunca altera la venta neta diaria. Con la corrección, el neto de ese cliente ese día es £649.50.

En resumen, los dos primeros episodios no los resuelve la limpieza sino el neteo diario, y el tercero lo resolvía el neteo diario hasta que nuestra limpieza eliminó la línea que lo compensaba. La lección es que eliminar una línea que compensa a otra es tan peligroso como conservar una línea errónea.

2.5. 1.5 Función de limpieza

Toda la limpieza está en la función `limpiar(df)` del archivo `limpiar.py`, que aplica las reglas en el orden de la Tabla 5, agrega una columna `Importe` y, opcionalmente, devuelve la bitácora. Las filas sin `CustomerID` se conservan; la Parte 6 las filtra al inicio. El mismo archivo contiene `cargar_datos()`, que lee el `.xlsx` con los identificadores como texto.

3. Parte 2: El calendario

3.1. 2.1 La serie diaria

La venta neta diaria es la suma de `Importe` de todas las líneas limpias de cada día, con las cancelaciones restando el día en que ocurren. Entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011 hay 374 días calendario, incluyendo ambos extremos, y hubo al menos una transacción en 305 de ellos. La Figura 3 muestra la serie; los cortes en la línea son los días sin transacciones.

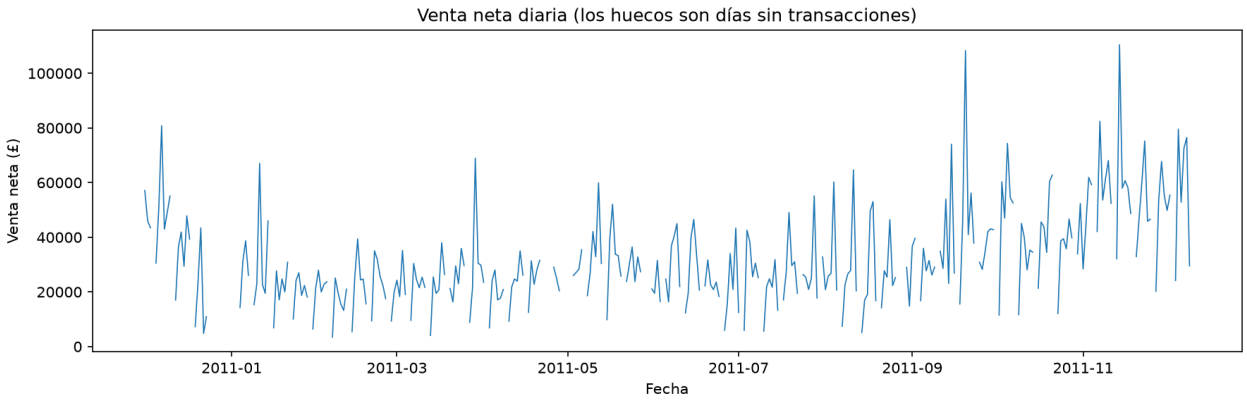


Figura 3: Venta neta diaria después de la limpieza.

Ningún día tiene venta neta negativa.

3.2. 2.2 Días sin transacciones

De los 69 días sin transacciones, 53 son sábados: la tienda no abre ese día (no hay transacciones en ninguno de los 53 sábados del periodo). Los 16 restantes se explican con el calendario de *bank holidays* de Inglaterra (Tabla 6).

Cuadro 6: Días sin transacciones que no son sábado.

Fecha	Día	Motivo
24/12/2010	viernes	Cierre de fin de año
26/12/2010	domingo	Boxing Day
27/12/2010	lunes	Navidad (feriado trasladado)
28/12/2010	martes	Boxing Day (feriado trasladado)
29–31/12/2010	mié.–vie.	Cierre de fin de año
02/01/2011	domingo	Cierre de fin de año
03/01/2011	lunes	Año Nuevo (feriado trasladado)
22/04/2011	viernes	Viernes Santo
24/04/2011	domingo	Domingo de Pascua
25/04/2011	lunes	Lunes de Pascua
29/04/2011	viernes	Boda real (feriado único)
02/05/2011	lunes	Early May bank holiday
30/05/2011	lunes	Spring bank holiday
29/08/2011	lunes	Summer bank holiday

En 2010, Navidad y Boxing Day cayeron en sábado y domingo, y Año Nuevo de 2011 en sábado, por lo que los feriados se trasladaron al lunes y martes siguientes. La boda del príncipe Guillermo el 29 de abril de 2011 fue un feriado que no se repite. Los feriados móviles son los de Semana Santa, cuya fecha depende del calendario lunar y varía entre marzo y abril, y los traslados de Navidad y Año Nuevo, que dependen del día de la semana en que caen. Los feriados de mayo y agosto cambian de fecha, pero siguen una regla fija (siempre son lunes). Los domingos la tienda sí abre: los tres domingos sin transacciones caen dentro de periodos de feriado.

3.3. 2.3 ¿Cero o dato faltante?

Depende del uso. Un día cerrado debe ser cero cuando interesa un total acumulado: la venta de una semana o un mes incluye los días cerrados con £0, y tratarlos como faltantes rompería la suma; lo mismo ocurre con la media móvil de 7 días calendario de la Parte 3. En cambio, debe ser un dato faltante cuando interesa el comportamiento de un día abierto, como al pronosticar la demanda o calcular promedios, índices estacionales o autocorrelaciones. Un sábado con £0 no refleja baja demanda sino que nadie pudo comprar; tratarlo como cero bajaría el promedio, inflaría la varianza e introduciría un patrón semanal artificial en la media, como el del proceso de la Parte 0.4(b).

3.4. 2.4 El último día

El último día de los datos, el viernes 9 de diciembre de 2011, está incompleto: su última factura es de las 12:50, cuando los viernes anteriores terminan entre las 17:00 y las 18:00, y tiene 48 facturas, contra 85 a 145 en los viernes de las cinco semanas previas. Compararlo con la mediana de todos los viernes del año (68 facturas y £26 132) sería engañoso, porque la serie tiene tendencia y las ventas

de fin de año son mucho mayores que las de principios de año: frente a los viernes recientes, de entre £46 000 y £62 000, el último día vendió alrededor de la mitad (£29 530), lo esperable para medio día. Lo eliminamos, porque introduciría al final de la serie una caída que no refleja la demanda. Como el periodo de prueba termina el 8 de diciembre, eliminarlo no afecta la evaluación.

De aquí en adelante usamos la serie sobre el calendario completo del 1 de diciembre de 2010 al 8 de diciembre de 2011 (373 días, 304 abiertos), con los días cerrados como faltantes. El entrenamiento va hasta el 30 de septiembre de 2011 (304 días, 245 abiertos) y la prueba son los 58 días abiertos del 3 de octubre al 8 de diciembre; el domingo 2 de octubre sirve como historia, pero no se evalúa.

4. Parte 3: Tendencia, estacionalidad y autocorrelación

4.1. 3.1 Tendencia

Calculamos una media móvil centrada de 7 días sobre el calendario completo, rellenando los días cerrados con cero, de modo que cada valor es la venta de la semana centrada en ese día dividida entre 7 (Figura 4).

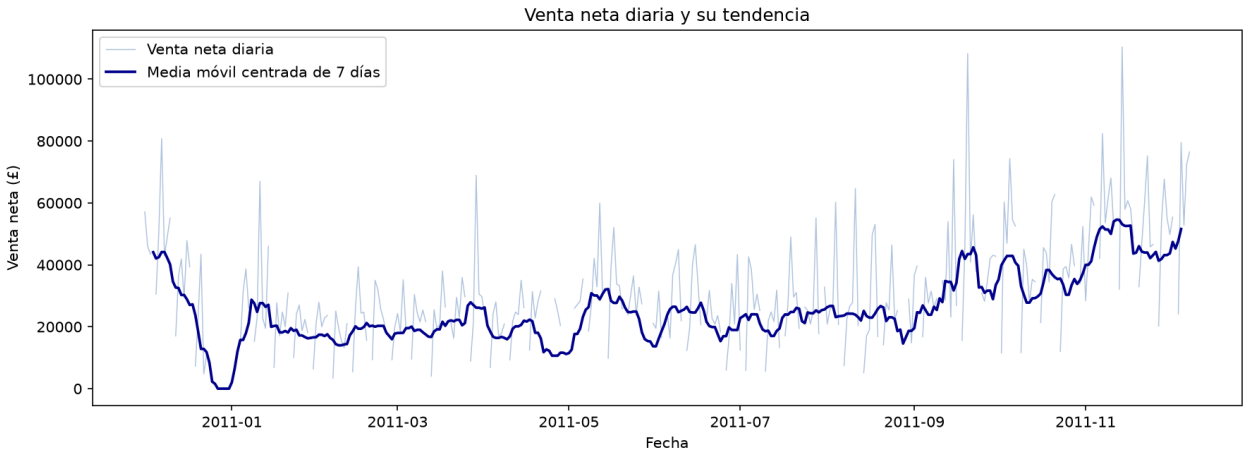


Figura 4: Venta neta diaria y media móvil centrada de 7 días.

Usamos 7 días porque es el periodo del ciclo semanal: la ventana contiene cada día de la semana exactamente una vez, incluido el sábado cerrado, y el patrón semanal se cancela. Con 5 días, la ventana incluiría algunos días de la semana y no otros, y la media subiría y bajaría cada semana según contuviera o no el sábado. Con 30 días, la media suavizaría en exceso, retrasaría los cambios de dirección y perdería 15 días en cada extremo de una serie de un solo año; además, 30 no es múltiplo de 7. La media es centrada para quedar alineada con el día que describe: una media hacia atrás describe el nivel de tres días antes y, cuando la serie sube, queda sistemáticamente por debajo. El costo es que usa días futuros, lo cual es aceptable para describir la serie pero no para pronosticarla.

La tendencia es casi plana de enero a agosto, con una media móvil entre £17 000 y £24 000 diarios, y sube con fuerza a partir de septiembre: £32 000 en septiembre, £35 000 en octubre y £47 000 en noviembre, el doble que en verano. Esto es consistente con una tienda de regalos que vende sobre todo a mayoristas, que se abastecen meses antes de Navidad. El entrenamiento termina justo cuando comienza este aumento, por lo que el periodo de prueba está en un nivel muy superior al de casi todo el entrenamiento.

4.2. 3.2 Estacionalidad

Para cada día abierto del entrenamiento calculamos el cociente y_t/MA_t, con la media móvil calculada solo con datos hasta el 30 de septiembre, para no usar información del periodo de prueba (los tres últimos días de septiembre quedan sin media móvil y no entran). El índice estacional de cada día de la semana es el promedio de sus cocientes (Tabla 7 y Figura 5).

Cuadro 7: Índices estacionales por día de la semana (entrenamiento).

Día	Índice	Días
Lunes	1.1717	37
Martes	1.5488	42
Miércoles	1.2273	41
Jueves	1.5660	41
Viernes	1.1075	38
Domingo	0.5768	40
Promedio	1.1997	

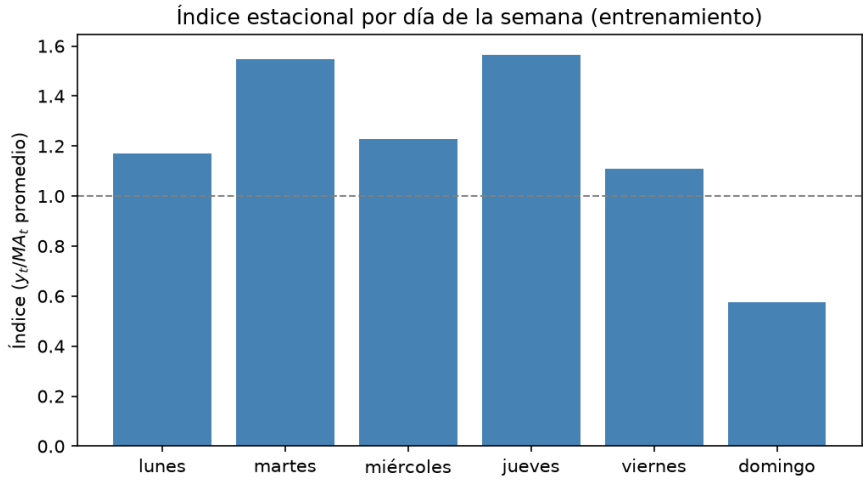


Figura 5: Índice estacional por día de la semana. La línea punteada marca 1.

Martes y jueves son los días de mayor venta, alrededor de 55 % por encima del nivel de la semana, seguidos de miércoles, lunes y viernes. El domingo vende poco más de la mitad del nivel semanal, consistente con una clientela mayorista que hace sus pedidos en días hábiles. La diferencia entre martes y jueves frente al miércoles podría deberse en parte a pedidos grandes aislados, ya que el índice es un promedio; la mediana de los cocientes sería una alternativa más robusta. Lunes y viernes tienen menos días porque en ellos caen la mayoría de los feriados.

El promedio de los seis índices es 1.20 y no 1 porque la media móvil reparte la venta semanal entre siete días, pero solo seis venden: si los seis días vendieran lo mismo, cada cociente sería $7/6 \approx 1.167$. El índice del sábado sería cero, y los siete índices promediarían alrededor de 1. El exceso sobre 7/6 viene de las semanas con feriados, en las que la venta se reparte entre cinco días abiertos y los cocientes son todavía mayores. Es común normalizar los índices para que promedien 1.

4.3. 3.3 Autocorrelación

Calculamos r_k para $k = 1, \ldots, 21$ sobre los 245 días abiertos del entrenamiento, una fila por día y sin calendario (Figura 6).

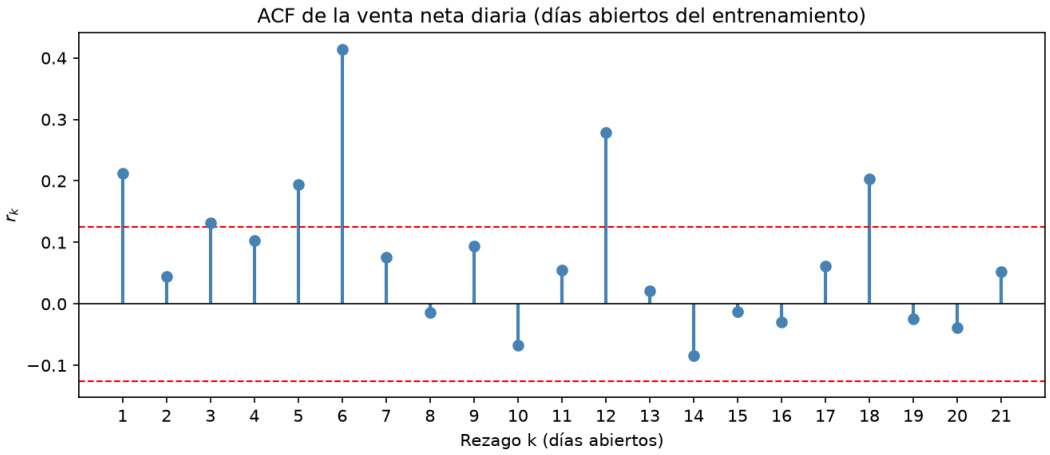


Figura 6: ACF de la venta neta diaria (días abiertos del entrenamiento). Las líneas rojas son las bandas $\pm 1.96/\sqrt{n}$, con $n = 245$.

(a) Se salen de las bandas 6 de los 21 rezagos (1, 3, 5, 6, 12 y 18), cuando bajo ruido blanco esperaríamos alrededor de uno. La serie no pasa la prueba de retardo 1 de la Tarea 2: $r_1 = 0.21$, por encima de la banda de 0.125. El pico está en el rezago 6 ($r_6 = 0.41$), que en el 88 % de los pares equivale a 7 días calendario: como el sábado no aparece entre las filas, una semana son seis filas. Los pares más separados corresponden a semanas con feriados, incluido el cierre de Navidad. Los picos se repiten en los rezagos 12 y 18, decayendo lentamente (0.41, 0.28, 0.20). Ljung–Box rechaza con fuerza la hipótesis de ruido blanco: $Q(6) = 71.6$ y $Q(12) = 97.6$, ambos con valor-p menor que 10^{-12}. A diferencia de la Parte 0.5, aquí $Q(6)$ sí alcanza el patrón semanal, porque en filas de días abiertos su periodo es 6.

(b) La ACF mezcla las dos razones para reprobar. Los picos en los rezagos 6, 12 y 18 se parecen a los del proceso semanal de la Parte 0.4(b), donde una media que depende del día de la semana produce un pico en el periodo sin que exista memoria; los índices de 3.2 confirman que la media cambia según el día. El valor de r_5 se explica en parte por las semanas con un feriado, en las que cinco filas separan el mismo día de la semana. Los valores positivos en rezagos bajos pueden deberse a memoria, pero también a la tendencia: como en la Parte 0.4(a), una media que sube produce r_k positivos en todos los rezagos. Con la ACF de la serie original no es posible separar ambas fuentes; para eso hay que quitar primero la estacionalidad y examinar el residuo, lo que hacemos en la Parte 4.

5. Parte 4: Del AR(1) al SARIMA

5.1. 4.1 Quitar la estacionalidad

Ajustamos por OLS la venta de los días abiertos del entrenamiento contra seis variables indicadoras de día de la semana, sin intercepto. Cada coeficiente es la venta promedio de su día: alrededor

de £35 000 los martes y jueves, entre £26 000 y £28 000 los lunes, miércoles y viernes, y £13 700 los domingos. La Figura 7 muestra la ACF de los residuos e_t.

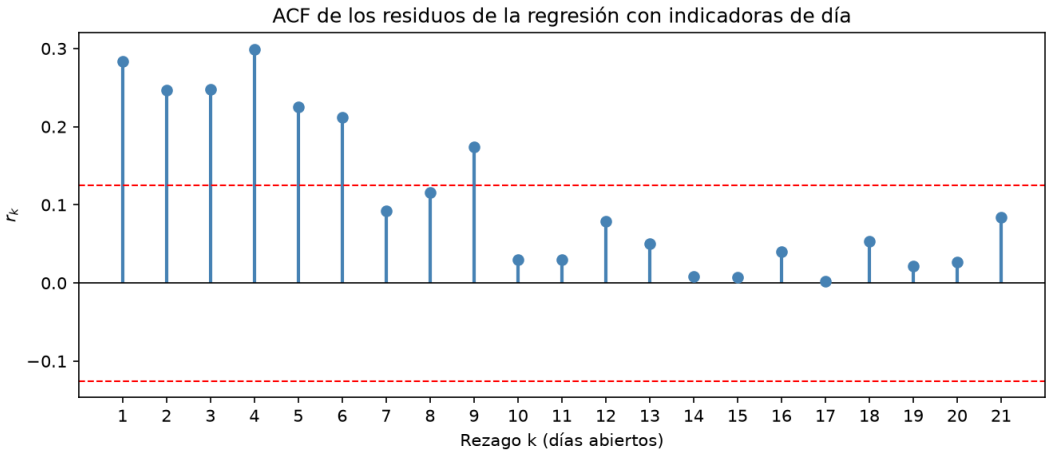


Figura 7: ACF de los residuos de la regresión con indicadoras de día.

Los picos semanales desaparecen: r_6 pasa de 0.41 a 0.21, y r_{12} y r_{18} quedan dentro de las bandas. Pero los rezagos 1 a 6 quedan todos entre 0.21 y 0.30, todos los rezagos son positivos y decaen lentamente, y Ljung–Box aumenta ($Q(6) = 97.1$, $Q(12) = 112.5$, valores-p menores que 10^{-17}). El aumento se debe a que, al quitar el patrón semanal, la varianza de la serie baja y la parte que viene del nivel cambiante pesa más.

Esta ACF no decae como ϕ^k: un AR(1) con $r_1 = 0.28$ tendría $r_2 \approx 0.08$ y $r_4 \approx 0.006$, mientras que aquí $r_4 = 0.30$ es mayor que r_1. Se parece en cambio a la del proceso con tendencia de la Parte 0.4(a), donde r_1 y r_7 eran casi iguales. Al modelo le falta la tendencia: supone que todos los días de la semana tienen la misma media durante el año, cuando un martes de septiembre vende mucho más que uno de febrero, de modo que cada día se parece a sus vecinos por estar del mismo lado de la media.

5.2. 4.2 Un AR(1) sobre los residuos

Ajustamos por OLS e_t contra e_{t-1} y obtuvimos $\hat{\phi} = 0.285$ ($\hat{c} = -100.7$, prácticamente cero porque los residuos tienen media cero). La Figura 8 muestra la ACF de los residuos $u_t = e_t - \hat{c} - \hat{\phi}\, e_{t-1}$.

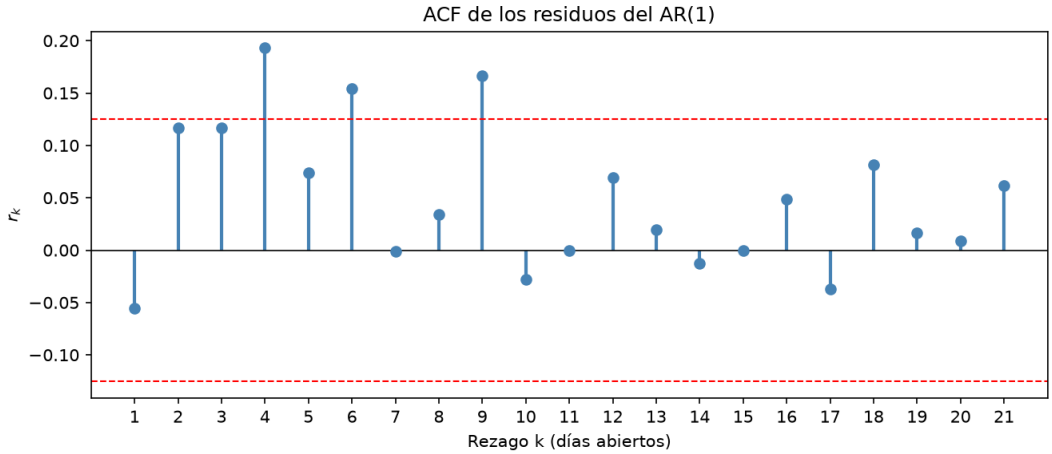


Figura 8: ACF de los residuos del AR(1) ajustado a e_t.

El AR(1) elimina la correlación de rezago 1 (r_1 pasa de 0.28 a -0.06), pero los rezagos 2 a 6 siguen siendo positivos y los rezagos 4, 6 y 9 quedan fuera de las bandas. Ljung–Box rechaza que los residuos sean ruido blanco: $Q(6) = 24.2$ con 5 grados de libertad ($p = 0.0002$) y $Q(12) = 33.0$ con 11 ($p = 0.0005$). El AR(1) no alcanza, porque modela una memoria corta que decae como ϕ^k, mientras que lo que encontramos en 4.1 es un nivel que cambia lentamente: el AR(1) corrige el rezago 1, pero no la correlación de los rezagos siguientes que proviene de ese nivel. Además, r_6 vuelve a salir de las bandas, lo que sugiere que el patrón semanal no es un efecto fijo en libras sino proporcional al nivel: cuando la venta sube en otoño, la diferencia entre días crece, y las indicadoras aditivas no lo capturan. Esto motiva el logaritmo y la diferencia estacional de 4.3.

5.3. 4.3 SARIMA

Ajustamos dos modelos SARIMA con $s = 6$ sobre el logaritmo de la venta de los días abiertos del entrenamiento, pasando a `SARIMAX` el arreglo de valores para que no interprete el calendario con huecos. S1 es un SARIMA$(1,0,0)(1,0,0)_6$ con constante: el logaritmo de la venta depende del día anterior y del mismo día de la semana anterior, alrededor de una media fija, y es estacionario. S2 es un SARIMA$(0,1,1)(0,1,1)_6$ sin constante, el modelo de aerolínea: modela la doble diferencia $(1-B)(1-B^6)\log y_t$, que elimina el nivel cambiante y el patrón semanal, y corrige el pronóstico con los errores recientes.

Usamos $s = 6$ porque, en filas de días abiertos, una semana son seis filas: el rezago 6 conecta cada día con el mismo día de la semana anterior. La suposición se rompe en las semanas con feriados, en las que seis filas atrás ya no es el mismo día de la semana, y alrededor del cierre de Navidad, donde seis filas pueden abarcar 17 o 18 días calendario; en 3.3 vimos que el 12 % de los pares a rezago 6 no estaban a siete días. Usamos el logaritmo porque el patrón semanal y las fluctuaciones son proporcionales al nivel, como sugirió 4.2: el logaritmo convierte un efecto multiplicativo en uno aditivo y estabiliza la varianza.

Cuadro 8: Parámetros estimados de S1 y S2 con el número máximo de iteraciones por defecto y con `maxiter=500`.

Modelo	Parámetro	Por defecto	`maxiter=500`
S1	Constante	1.8838	4.2679
	AR(1), ϕ	0.1605	0.1294
	AR estacional, Φ	0.7742	0.5158
	σ^2	0.2310	0.2194
	¿Convergió?	No (50 it.)	Sí (72 it.)
S2	MA(1), θ	-0.9086	-0.9086
	MA estacional, Θ	-0.6849	-0.6849
	σ^2	0.2150	0.2150
	¿Convergió?	Sí (16 it.)	Sí (16 it.)

S1 no convergió con la configuración por defecto, y al aumentar las iteraciones los parámetros cambian sustancialmente: el coeficiente autorregresivo estacional pasa de 0.77 a 0.52 y la constante de 1.88 a 4.27. La dificultad viene de que la media implícita del modelo, $c/[(1-\phi)(1-\Phi)]$, se obtiene con muchas combinaciones de parámetros, lo que aplana la verosimilitud en esa dirección. En la versión convergida, esa media es 10.12 en logaritmo, unos £24 800 diarios. S2 convergió en 16 iteraciones y no cambia al aumentarlas. Sus parámetros equivalen a un suavizamiento exponencial: con $\theta = -0.91$, el nivel se actualiza con alrededor del 9 % de cada sorpresa, y con $\Theta = -0.68$, el patrón semanal con alrededor del 32 %. En lo que sigue usamos la versión convergida de cada modelo.

5.4. 4.4 Diagnóstico

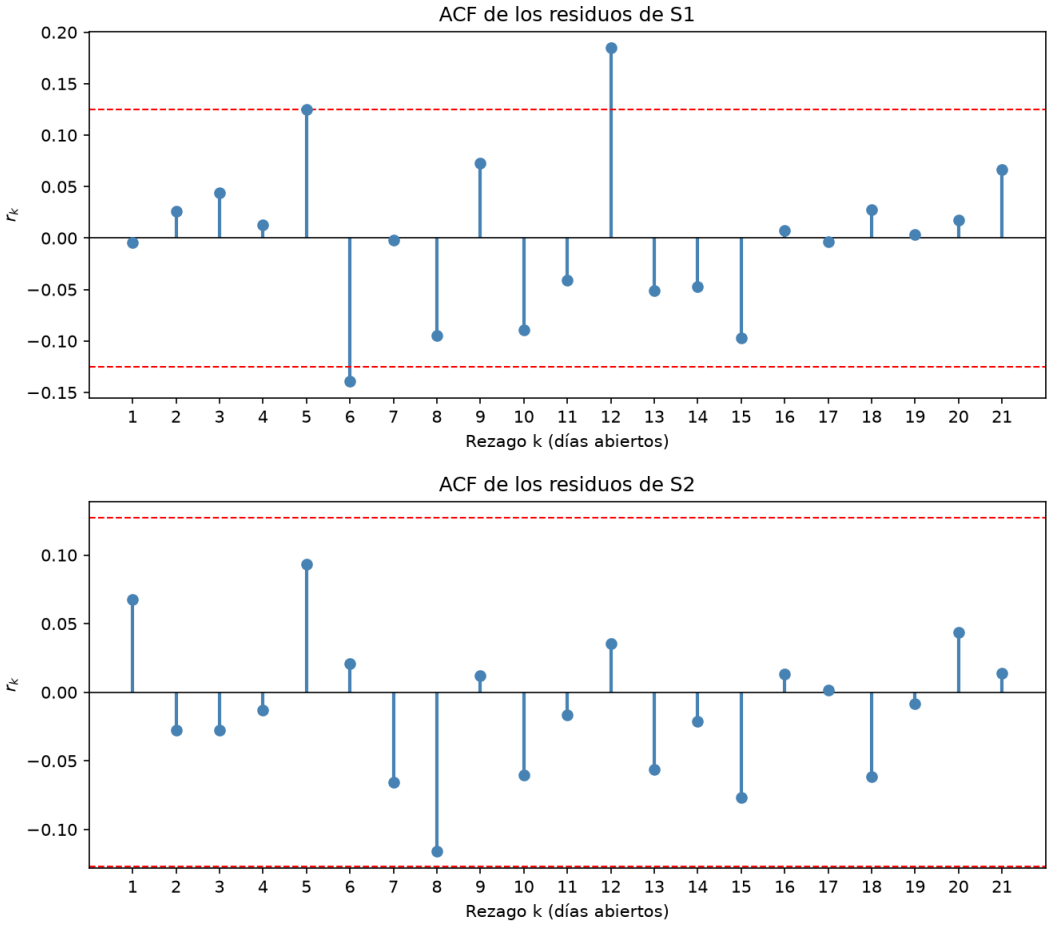


Figura 9: ACF de los residuos de S1 (arriba, $n = 245$) y de S2 (abajo, $n = 238$, sin los primeros 7 residuos).

Cuadro 9: Prueba de Ljung–Box sobre los residuos, con $m - 2$ grados de libertad.

Modelo	$Q(6)$	p	$Q(12)$	p
S1	9.56	0.049	24.56	0.006
S2	3.74	0.443	9.48	0.487

S2 deja residuos compatibles con ruido blanco: ningún rezago sale de las bandas y Ljung–Box no rechaza con ninguna de las dos ventanas. S1 no: los rezagos estacionales 6 y 12 salen de las bandas y $Q(12)$ rechaza con claridad ($p = 0.006$). S1 tiene un solo término autorregresivo estacional alrededor de una media fija, que no puede representar un patrón semanal persistente ni un nivel que cambia; S2 elimina ambos con las diferencias $(1 - B)$ y $(1 - B^6)$. Que S2 pase la prueba no demuestra que sea el modelo correcto, solo que no queda autocorrelación detectable en los primeros 12 rezagos.

5.5. 4.5 Pronósticos a largo plazo

S1 es estacionario: como un AR(1) con $|\phi| < 1$, sus pronósticos convergen a la media del proceso a medida que crece el horizonte. El efecto del día anterior desaparece en pocos días y el del patrón semanal decae a razón de 0.52 por semana, hasta llegar a la media implícita de 10.12 en logaritmo, unos £24 800 diarios. Ese nivel corresponde a un año mayormente plano, muy por debajo de los £35 000 a £47 000 de octubre y noviembre. S2 no es estacionario: como una caminata aleatoria, sus pronósticos no regresan a una media, sino que repiten indefinidamente el último nivel y el último patrón semanal estimados. Al no tener constante, no extrapola una pendiente, y su incertidumbre crece sin límite con el horizonte, mientras que la de S1 se estabiliza.

6. Parte 5: Pronóstico y fuga

6.1. 5.1 Los modelos

Cada domingo, con todo lo observado hasta ese día, pronosticamos los días abiertos de la semana siguiente; luego avanzamos una semana, reajustamos y repetimos. Implementamos B1 (media histórica de los días abiertos), B2 (naive estacional: el valor del mismo día de la semana abierto más reciente), M1 (OLS con tendencia lineal en días transcurridos e indicadoras de día) y M2 (OLS con indicadoras de día y los rezagos y_{t-7} e y_{t-14}). Para M2, cuando un rezago cae en un día cerrado usamos el mismo día de la semana abierto más reciente; aplicamos la regla tanto a y_{t-7} como a y_{t-14}, de modo que para el 9 de mayo ambos rezagos son el 18 de abril, porque el 2 y el 25 de abril fueron feriados. S1 y S2 se reajustan en cada origen con la configuración que convergió en 4.3 (S1 con `maxiter=500`); los 64 ajustes convergieron.

M2 puede usar y_{t-7} para cualquiera de los siete días siguientes porque todos caen entre el lunes y el domingo posteriores al origen, de modo que su día $t-7$ es el domingo del origen o anterior, y ya fue observado. No podría usar y_{t-1}: para pronosticar el martes, y_{t-1} sería el lunes de la misma semana, que aún no ocurre en el origen. S1 usa el rezago 1 de forma recursiva: pronostica el lunes con el domingo observado y, para el martes, sustituye el lunes desconocido por su propio pronóstico, y así sucesivamente, por lo que su precisión se deteriora con el horizonte.

6.2. 5.2 Tres formas de estimar el error

Cuadro 10: MAE y RMSE (£) de cada modelo. (a) Validación cruzada aleatoria de 5 *folds* sobre los 233 días del entrenamiento con ambos rezagos disponibles, con 10 semillas (0 a 9); entre paréntesis, la desviación estándar entre semillas. (b) Origen móvil dentro del entrenamiento (22 orígenes, 128 días). (c) Periodo de prueba con origen móvil (10 orígenes, 58 días).

	(a) CV aleatoria		(b) Origen móvil		(c) Prueba	
Modelo	MAE	RMSE	MAE	RMSE	MAE	RMSE
B1	9 544 (26)	13 537 (29)	10 228	14 886	22 409	26 927
B2	—	—	11 269	15 574	14 140	18 357
M1	8 176 (60)	11 284 (94)	9 766	13 825	15 179	20 142
M2	8 361 (92)	11 787 (190)	9 223	13 357	15 232	19 808
S1	—	—	9 724	13 742	16 708	20 935
S2	—	—	10 041	13 971	12 354	15 688

La validación cruzada aleatoria no tiene sentido para B2, S1 y S2 porque están definidos por el orden de los datos: usan el día anterior, el mismo día de la semana más reciente o la fila de hace seis. Con *folds* aleatorios, la historia tiene huecos y mezcla días anteriores y posteriores a los que se pronostican, de modo que esos rezagos pierden su significado. B1, M1 y M2 son regresiones en las que cada fila es autónoma, por lo que pueden evaluarse así, aunque eso no garantiza una buena estimación.

El origen móvil (b) se acerca más al error de prueba que la validación aleatoria (a) en los tres modelos. La validación aleatoria interpola en lugar de extrapolar: para pronosticar un día de julio, el modelo se entrena con días de agosto y septiembre, y M1, por ejemplo, estima la tendencia con puntos a ambos lados del día pronosticado. Sus desviaciones estándar son pequeñas: es una estimación precisa pero sesgada. Sin embargo, ninguna de las dos se acerca de verdad: el error de prueba es entre 1.2 y 2.2 veces el de (b). Tampoco aciertan el orden de los modelos: (a) favorece a M1 y (b) a M2, mientras que en la prueba gana S2, que en (b) era el cuarto.

6.3. 5.3 El ganador

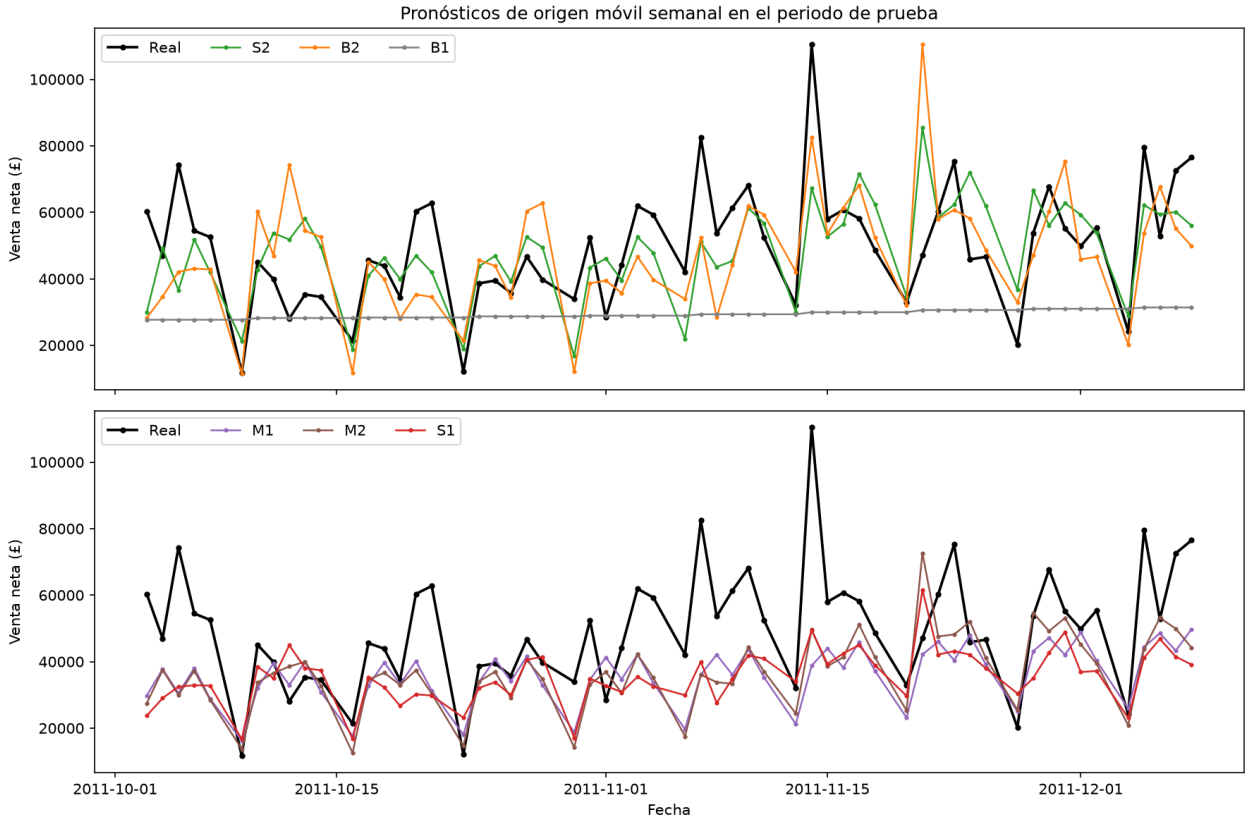


Figura 10: Pronósticos de origen móvil semanal en el periodo de prueba. Arriba, S2, B2 y B1; abajo, M1, M2 y S1. En negro, la venta real.

Cuadro 11: Error medio (real menos pronóstico) en el periodo de prueba.

Modelo	Error medio (£)
B1	20 444
S1	14 252
M1	13 702
M2	12 942
B2	2 736
S2	1 244

S2 gana en la prueba, con el menor MAE y el menor RMSE. La Figura 10 y la Tabla 11 muestran por qué. B1, M1, M2 y S1 subestiman la venta en promedio entre £13 000 y £20 000 diarios: capturan la forma de la semana, pero no el aumento de nivel de la temporada navideña. M1 estima una sola pendiente con un año casi plano hasta agosto, por lo que no alcanza la aceleración de otoño; M2 reacciona a las semanas recientes mediante sus rezagos, pero con coeficientes estimados en un periodo tranquilo; S1 es estacionario y sus pronósticos regresan a una media fija de unos £24 800 (4.5); y B1 promedia todo el año.

B2 y S2, los dos modelos no estacionarios, son los únicos prácticamente insesgados, porque parten de lo más reciente. S2 supera a B2 porque suaviza: B2 copia completa la semana anterior, de modo que el pico del 14 de noviembre (£110 000) se repite como pronóstico del 21 de noviembre, cuando la venta real fue de £47 000; S2 reacciona solo en parte, porque actualiza su nivel y su patrón semanal con una fracción de cada sorpresa (4.3). La diferencia se nota sobre todo en el RMSE, que penaliza los errores grandes. Esto es consistente con el diagnóstico de 4.4: S2 era el único modelo cuyos residuos parecían ruido blanco, es decir, el único que capturaba el nivel cambiante y el patrón semanal proporcional. Ningún modelo anticipa los picos aislados, como los del 7 y el 14 de noviembre, que corresponden a pedidos grandes sin patrón.

6.4. 5.4 La trampa

Cuadro 12: M2 con y sin la media móvil centrada de 7 días como predictor. Errores en libras; validación como en la Tabla 10.

Modelo	MAE (a)	RMSE (a)	MAE (b)	RMSE (b)
M2	8 361 (92)	11 787	9 223	13 357
M2 + MA7	7 415 (80)	10 053	8 237	11 262

Agregar la media móvil centrada de 7 días a M2 reduce el MAE en alrededor de 11 % tanto en (a) como en (b), de modo que el modelo parece mejor. Sin embargo, el predictor es ilegal: la media móvil centrada del día t promedia los días $t-3$ a $t+3$, que incluyen el propio día que se pronostica y tres días posteriores. El origen móvil no lo detecta porque controla qué filas se usan para entrenar, pero no qué información contiene cada columna: si la media móvil se calcula una sola vez sobre toda la serie, la información futura ya está incorporada en los predictores antes de la validación. La fuga no está en la partición de los datos, sino en la construcción de las variables. Por la misma razón, (c) no puede calcularse sin hacer trampa: para pronosticar un día de la semana siguiente al origen, se necesitaría su media móvil, que depende de las ventas de ese mismo día y de los tres siguientes, que no se conocen en el origen; obtenerla exige usar las ventas reales del periodo de prueba. Los últimos

tres días de la prueba ni siquiera tienen media móvil. Una versión legal de la idea sería usar la media de los siete días que terminan en el origen.

6.5. 5.5 ¿Por qué falla la validación?

Todas las estimaciones hechas dentro del entrenamiento subestiman el error de prueba, por dos causas distintas. La primera es la partición: la validación aleatoria mezcla pasado y futuro e interpola entre días vecinos, por lo que es más optimista que el origen móvil. Esta causa se arregla con una mejor validación, y explica la diferencia entre (a) y (b). La segunda es que la serie cambió: el periodo de prueba es la temporada navideña, con un nivel mucho más alto y pedidos más grandes que casi todo el entrenamiento, que no contiene un otoño completo. Ningún esquema de validación dentro del entrenamiento puede revelar un comportamiento que no está en los datos; solo más años de historia o conocimiento del negocio lo resolverían. Esta causa explica la diferencia entre (b) y (c), y afecta más a los modelos que suponen un nivel fijo: el MAE de B1 se duplica de (b) a (c), mientras que el de S2 aumenta 23 %. Parte del aumento es además de escala, porque con ventas mayores los errores en libras también crecen.

Con un solo año de datos no se puede estimar la estacionalidad anual: hay una sola observación de cada época del año, de modo que no es posible distinguir si noviembre vende el doble que el verano porque siempre ocurre así o porque el negocio creció. La estacionalidad anual y la tendencia son indistinguibles con una sola realización de cada temporada.

7. Parte 6: RFM

7.1. 6.1 Recencia, frecuencia y monto

Con los datos limpios que tienen `CustomerID` y solo las transacciones anteriores al 1 de octubre de 2011, calculamos para cada cliente la recencia (días entre su última factura de venta y el 1 de octubre), la frecuencia (facturas de venta distintas, sin contar cancelaciones) y el monto (venta neta, con las cancelaciones restando). De los 3 648 clientes con alguna transacción antes del corte, 35 solo tienen cancelaciones, probablemente devoluciones de compras anteriores al inicio de los datos; al no tener compras observables, no tienen recencia ni frecuencia y los excluimos. Quedan 3 613 clientes.

La clientela es muy desigual. La recencia mediana es de 65 días, con un rango de 1 a 304. La frecuencia mediana es de 2 facturas y al menos una cuarta parte de los clientes compró una sola vez, pero el máximo es 138. El monto mediano es de £576, mientras que el promedio es de £1 609 y el máximo de £201 877: unos pocos clientes grandes concentran buena parte de la venta.

Ocho clientes tienen $M \leq 0$. Cuatro tienen $M = 0$ porque cancelaron todo lo que compraron, entre ellos el cliente 12346, que pidió y canceló 74 215 frascos el mismo día (1.4); los otros cuatro tienen monto negativo, probablemente por devoluciones de compras anteriores al periodo. Los conservamos, porque son clientes que sí compraron, y su monto los coloca naturalmente en el puntaje más bajo de M. Es importante no usar nada posterior al 1 de octubre porque en 6.3 evaluamos si R, F y M predicen las compras entre el 1 de octubre y el 8 de diciembre: si se calcularan con datos de ese periodo, un cliente que compró en octubre tendría una recencia pequeña precisamente por haber comprado, y el predictor contendría la respuesta, la misma fuga de 5.4.

7.2. 6.2 Puntajes

Asignamos a cada cliente un puntaje de 1 a 5 en cada dimensión según su quintil; en recencia, 5 corresponde a los clientes más recientes. La frecuencia presenta un problema: el 40.2 % de los clientes compró una sola vez, de modo que los clientes con $F = 1$ ocupan más de dos quintiles y los

cortes de los quintiles coinciden $(1, 1, 1, 3, 5, 138)$; no es posible repartirlos en grupos distintos según su frecuencia, porque todos tienen el mismo valor. Para desempatar, ordenamos a los 3 613 clientes por `CustomerID`, los barajamos con `numpy.random.default_rng(2026).permutation` y aplicamos `pd.qcut` a `F.rank(method='first')`. La Tabla 13 muestra los rangos resultantes.

Cuadro 13: Rango de cada variable por puntaje.

Puntaje	R (días)	F (facturas)	M (£)
1	177–304	1	−141 a 223
2	95–176	1	224 a 412
3	43–94	1–3	412 a 787
4	16–41	3–5	788 a 1 685
5	1–15	5–138	1 693 a 201 877

Los clientes con $F = 1$ se reparten al azar entre los puntajes 1, 2 y 3; los de $F = 3$, entre 3 y 4; y los de $F = 5$, entre 4 y 5. Para dos clientes con la misma frecuencia que caen en puntajes distintos, la diferencia no contiene ninguna información: depende solo del orden aleatorio. El puntaje deja de ser una función de F, ya que con otra semilla cientos de clientes cambiarían de puntaje, y en cualquier análisis por puntaje las diferencias entre los puntajes 1 y 2 de frecuencia serán ruido. Ese ruido también entra en la suma de los tres puntajes.

7.3. 6.3 ¿Quién vuelve a comprar?

Definimos $\text{compra}_i = 1$ si el cliente tuvo al menos una factura de venta entre el 1 de octubre y el 8 de diciembre de 2011; el 50.8 % de los 3 613 clientes volvió a comprar. La Tabla 14 muestra la fracción que compró por puntaje y la Tabla 15 el AUC de cada variable, con los valores crudos (la recencia con el signo invertido) y con la suma de los tres puntajes.

Cuadro 14: Fracción de clientes que compró entre el 1 de octubre y el 8 de diciembre, por puntaje.

Puntaje	R	F	M
1	0.278	0.324	0.296
2	0.381	0.313	0.373
3	0.554	0.458	0.458
4	0.662	0.590	0.605
5	0.661	0.855	0.808

Cuadro 15: AUC como clasificadores de compra_i.

Variable	AUC
Recencia (signo invertido)	0.673
Frecuencia	0.721
Monto	0.708
Suma de puntajes	0.734

La frecuencia es la dimensión que mejor separa: tiene el mayor AUC y la fracción de compra va de 32 % en el puntaje 1 a 86 % en el 5. El monto queda cerca y la recencia en último lugar. La suma de

los puntajes mejora poco sobre la frecuencia sola, porque las tres dimensiones están correlacionadas. Como anticipamos en 6.2, los puntajes 1 y 2 de frecuencia tienen tasas prácticamente iguales: ambos contienen solo clientes con $F = 1$, separados por el desempate aleatorio.

El desempeño de la recencia es llamativo: los puntajes 4 y 5 tienen la misma tasa, y casi un tercio de los clientes con el puntaje más bajo, que no compraban desde hacía entre seis y diez meses, volvió a comprar. Una explicación es que el periodo evaluado es la temporada navideña: muchos clientes con recencia alta compraron por última vez en diciembre de 2010 o enero de 2011 y son compradores de temporada, para quienes una recencia de 300 días no indica abandono. Es otra manifestación de la estacionalidad anual que no podemos estimar con un solo año de datos.

7.4. 6.4 Campeones

Los 783 clientes con puntaje 4 o 5 en las tres dimensiones son el 21.7 % de los clientes de 6.1, pero generaron el 53.3 % de la venta neta del 1 de octubre al 8 de diciembre de todos los clientes con `CustomerID` (£1.28 millones de £2.40 millones), y el 81.2 % de ellos volvió a comprar, frente al 50.8 % general. La venta está muy concentrada: uno de cada cinco clientes produce más de la mitad del ingreso.

7.5. 6.5 Clientes nuevos

Los 723 clientes sin ninguna factura de venta antes del 1 de octubre, el 27.9 % de los clientes activos en el periodo, generaron £378 213, el 15.8 % de la venta neta del 1 de octubre al 8 de diciembre de los clientes con `CustomerID`. Ni un análisis RFM ni ningún modelo construido cliente por cliente puede pronosticar esa venta: esos clientes no tienen historia, no tienen recencia, frecuencia ni monto, y al momento del corte ni siquiera forman parte de la lista de clientes a pronosticar.

En el vocabulario de FPP2, la Parte 5 es un pronóstico *top-down*: se pronostica directamente la serie total. Un modelo cliente por cliente es *bottom-up*: pronostica a cada cliente conocido y suma. Solo el pronóstico *top-down* puede ver a los clientes nuevos, porque la serie agregada incluye su venta; al adaptarse al aumento de nivel de octubre y noviembre, S2 capturaba implícitamente también la llegada de clientes nuevos. Un pronóstico *bottom-up* subestimará el total al menos en esa proporción, a menos que se complemente con un modelo de adquisición de clientes, lo que es relevante para la comparación del proyecto. Además, ese 15.8 % se calcula solo sobre las ventas con `CustomerID`: las ventas anónimas, cerca del 15 % del total según 1.2(f), también son invisibles para un modelo cliente por cliente, pero forman parte de la serie agregada.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015.

[2] D. Chen, S. L. Sain y K. Guo. Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3):197–208, 2012.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018.

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.